

训练、推理资源计算公式

公式一：总算力需求

$$C_{total} = \frac{P \times D \times \text{系数} \times 10^{18}}{MFU \times 10^{15}}$$

符号	含义	单位
P	被训练参数量	B（十亿）
D	训练数据量	Btokens（十亿 tokens）
系数	微调方式系数（查表）	无量纲
MFU	有效利用率，通常取 0.2	0~1
C_total	总算力需求	PFLOPS

关于 10^18 和 10^15：纯单位换算。P×D 算出来的原始单位是 FLOPs，1 PFLOPS = 10^15 FLOPs，所以除以 10^15 把单位换成 PFLOPS。上下两个幂次合并后等于 ×10^3，没有特殊含义。

公式二：单卡算力需求（按训练周期折算）

$$C_{card} = \frac{C_{total}}{T_{days} \times 86400}$$

符号	含义
T_days	训练周期（天）
86400	每天的秒数
C_card	每张卡每秒需要完成的算力（PFLOPS）

含义：总工作量固定，训练周期越短 → 单卡需求越高 → 需要更多卡；反之周期越长 → 需要更少卡。

公式三：卡数 → 节点数

$$N_{cards} = \lceil \frac{C_{card}}{FP16_{card}} \rceil$$

$$N_{nodes} = \lceil \frac{N_{cards}}{cards_per_node} \rceil$$

$$N_{actual} = N_{nodes} \times cards_per_node$$

⚠️ 两次向上取整，缺一不可

- 第一次：卡数有小数 → 向上取整 (33.6 → 34 张)
- 第二次：卡数对齐节点规格 → 再向上取整 (34 ÷ 8 = 4.25 → 5 节点 = 40 张卡)
- 节点冗余 (40 vs 34) 是正常的，由硬件粒度决定，无法避免

微调系数表

微调方式	算力系数	显存倍率 (×参数量)	原因
LoRA-BF16	0.014	2×	只更新少量参数，工作量极小
FULL-BF16	6.82	18×	接近理论值 6PD，全量更新
QLoRA-4bit	0.014	0.5×	量化 LoRA，显存极度受限时使用
GRPO-BF16	9.07	40×	需要同时跑多个模型做强化学习
PPO-BF16	13.64	60×	Actor + Critic + 参考模型，工作量最大

🏠 训练完整示例

场景：kimi-k2.5，GRPO-BF16 微调，目标 20 天完成，使用 GB300 卡

已知条件：

参数	值
P (被训练参数量)	32 B
D (训练数据量)	100 Btokens
系数 (查表 GRPO-BF16)	9.07
MFU	0.2
T_days (训练周期)	20 天
GB300 单卡 FP16 算力	2.5 PFLOPS

参数	值
节点规格	8 卡 / 节点

第一步：总算力需求

$$C_{total} = \frac{32 \times 100 \times 9.07 \times 10^{18}}{0.2 \times 10^{15}} = 145,120,000 \text{ PFLOPS}$$

第二步：单卡算力需求

$$C_{card} = \frac{145,120,000}{20 \times 86400} = 83.98 \text{ PFLOPS}$$

第三步：理论卡数（第一次向上取整）

$$N_{cards} = \lceil \frac{83.98}{2.5} \rceil = \lceil 33.59 \rceil = 34 \text{ 张}$$

第四步：节点对齐（第二次向上取整）

$$N_{nodes} = \lceil \frac{34}{8} \rceil = \lceil 4.25 \rceil = 5 \text{ 个节点}$$

$$N_{actual} = 5 \times 8 = 40 \text{ 张卡}$$

结论：需要 5 个节点（40 张 GB300 卡），硬件冗余 = $(40-34)/34 = 17.6\%$

推理显存公式

$$V_{total} = V_{weight} + V_{activation} + V_{KV} + V_{overhead}$$

KV Cache

$$V_{KV} = \frac{2 \times L \times K \times T \times B \times bytes}{10^9} \text{ (GB)}$$

符号	含义
L	模型层数
K	KV 维度（MLA 结构取 576，标准 MHA 取 1024）
T	上下文长度（tokens，如 131072）
B	并发用户数
bytes	精度字节数（BF16=2，FP8=1）

MLA vs MHA: MLA 结构 (kimi、deepseek、glm 等) KV 维度只有 576, 比标准 MHA 的 1024 小 43%, KV Cache 更小, 推理更省显存。

激活值

$$V_{activation} = V_{KV} \times 0.2$$

系统 Overhead

$$V_{overhead} = (V_{weight} + V_{activation} + V_{KV}) \times 10\%$$

已验证：6 个模型 Overhead 均为总显存的恰好 10%，无任何偏差。

推理 → 卡数 → 节点数

$$N_{cards} = \lceil \frac{V_{total}}{V_{card}} \rceil$$

$$N_{nodes} = \lceil \frac{N_{cards}}{cards_per_node} \rceil$$

⚠ 同样必须两次向上取整，不能直接报小数节点数。

 推理完整示例

场景：kimi-k2.5 推理部署，131K 上下文，50 并发用户，使用 H100-SXM 卡

已知条件：

参数	值
权重（查模型库，BF16）	554 GB
L（模型层数）	61 层
K（KV 维度，MLA 结构）	576
T（上下文长度）	131,072 tokens
B（并发用户数）	50
bytes（BF16 精度）	2
H100-SXM 单卡显存	80 GB
节点规格	8 卡 / 节点

第一步：KV Cache

$$V_{KV} = \frac{2 \times 61 \times 576 \times 131072 \times 50 \times 2}{10^9} \approx 462 \text{ GB}$$

第二步：激活值

$$V_{activation} = 462 \times 0.2 = 92 \text{ GB}$$

第三步：Overhead

$$V_{overhead} = (554 + 92 + 462) \times 10\% = 111 \text{ GB}$$

第四步：总显存

$$V_{total} = 554 + 92 + 462 + 111 = 1,219 \text{ GB}$$

第五步：理论卡数（第一次向上取整）

$$N_{cards} = \lceil \frac{1219}{80} \rceil = \lceil 15.24 \rceil = 16 \text{ 张}$$

第六步：节点对齐（第二次向上取整）

$$N_{nodes} = \lceil \frac{16}{8} \rceil = 2 \text{ 个节点}$$

$$N_{actual} = 2 \times 8 = 16 \text{ 张卡}$$

结论：需要 2 个节点（16 张 H100-SXM 卡），实际显存 = 1280 GB，利用率 = 1219/1280 = 95.2%

三条铁律

1. 卡数有小数，必须向上取整（33.6 张 → 34 张）
2. 卡数对齐节点，再做一次向上取整（34 ÷ 8 = 4.25 → 5 节点）
3. 节点冗余是正常的（40 vs 34，冗余 18%，由硬件粒度决定，无法避免）